

# Detecção de Arritmias Cardíacas com WiSARD

Ygor Canalli<sup>1</sup>

<sup>1</sup> Programa de Engenharia de Sisemas e Computação  
COPPE - Universidade Federal do Rio de Janeiro (COPPE/UFRJ)

canalli@cos.ufrj.br

**Resumo.** *Este trabalho tem por objetivo avaliar o desempenho do modelo WiSARD no problema de classificar arritmias cardíacas. Utilizando-se da técnica de bleaching, uma codificação adequada da entrada, além da criação de classificadores específicos de acordo com o sexo do paciente, foi possível ultrapassar em 0,24% a acurácia publicada anteriormente no Dataset em questão.*

## 1. Introdução

Ao longo dos anos diversas técnicas computacionais tem sido empregadas no problema de detectar e classificar arritmias cardíacas a partir da análise de sinais de Eletrocardiograma (ECG). Podemos destacar técnicas como Projeção de Features [Güvenir et al. 1997], Métodos de Lógica Nebulosa [Salem et al. 2009, Karhe 2014], Redes Neurais Artificiais (ANN) [Salem et al. 2009, Karhe 2014], Máquinas de Vetores de Suporte (SVM) [Salem et al. 2009, Karhe 2014], Modelo Oculto de Markov [Salem et al. 2009], Processamento de Sinais [Karhe 2014] e Computação Evolucionária [Karhe 2014, Martin-Garcia et al. 2014].

O objetivo do presente trabalho é avaliar o desempenho do modelo WiSARD [Aleksander et al. 1984] no problema de classificação de arritmias cardíacas. Para tanto, será utilizado o mesmo *Dataset* utilizado em [Güvenir et al. 1997], no qual o modelo supervisionado VFI5, desenvolvido especialmente para o problema, foi capaz de alcançar uma acurácia de 62%.

A divisão texto é como segue: no Capítulo 2 o *Dataset* utilizado é descrito; o Capítulo 3 descreve como o modelo WiSARD foi utilizado para obter-se bons resultados no problema de classificação de arritmias cardíacas; o Capítulo 4 apresenta os resultados obtidos no presente estudo. Por fim, o Capítulo 5 traz uma conclusão ao trabalho.


## 2. Descrição dos Dados

O *Dataset* utilizado foi desenvolvido especialmente para avaliação do Algoritmo VFI5 [Güvenir et al. 1997], e foi disponibilizado em [UCI Machine Learning Repository 1998]. O *Dataset* possui 452 amostras, cada qual relativa a um paciente, e está dividido em 16 classes:

1. Normal
2. Mudanças isquêmicas (Doença da Artéria Coronária)
3. Infração Miocardial Anterior
4. Infração Miocardial Inferior
5. Taquicardia do Sinus
6. Braquicardia do Sinus

7. Contração Centricular Prematura
8. Contração Supraventricular Prematura
9. Bloqueio do Ramo Esquerdo
10. Bloqueio do Ramo Direito
11. Bloqueio Atrioventricular de Primeiro Grau
12. Bloqueio Atrioventricular de Segundo Grau
13. Bloqueio Atrioventricular de Terceiro Grau
14. Hipertrofia do Ventrículo Esquerdo
15. Fibrilação ou Palpitação Atrial
16. Outros

O *Dataset* é extremamente desbalanceado, sendo mais da metade das amostras da Classe 1. Além disso, as classes 11, 12 e 13 não possuem instâncias. Assim, a Figura 1 apresenta a distribuição das amostras.




**Figura 1. Distribuição das classes no *Dataset***

Cada amostra é composta por 279 atributos, dos quais 206 são contínuos e 73 categóricos, sendo cerca de 0,43% dos dados contínuos faltosos. Desta forma, parte dos atributos é relativo a informações clínicas, a saber: idade, sexo, peso e altura do paciente; os demais atributos são informações extraídas de ECG. Cada amostra possui informações coletadas a partir de diversos canais do ECG: DI até DIII, V1 até V6, AVR, AVL e AVF. De cada canal são coletadas informações sobre certas ondas especiais, como por exemplo as ondas Q, R e S. A Figura 2 mostra um trecho ilustrativo de ECG apresentando tais ondas. Adicionalmente, são trazidas informações gerais sobre o eletrocargiograma, como por exemplo a frequência cardíaca e valores médios dentre todos os canais. A lista completa de atributos extraídos do ECG é apresentada abaixo.

- Informações relativas a cada canal
  - Largura média (mseg) das ondas: Q, R, S, R' e S'
  - Número de defleções intrínsecas
  - Existência de imperfeições nas ondas: R, P e T
  - Existência de derivação difásica nas ondas: R, P e T
  - Amplitude (0,1 \* milivolt) das ondas: JJ, Q, R, S, R', S', P e T

- QRSA (soma das áreas de todos os segmentos dividido por 10)
- QRSTA ( $QRSA + 0,5 * [\text{largura da onda T}] * 0,1 * [\text{altura da onda T}]$ )
- Informações gerais
  - Média das durações (mseg) QRS
  - Média dos intervalos (mseg): P-R, Q-T, T-T e P-P
  - Ângulos do vetor (graus) no plano frontal de: QRS, T, P, QRST e J
  - Frequência cardíaca (bpm)



**Figura 2. Ondas do Eletrocardiograma. Fonte: [Life in The Fastlane ]**

### 3. Detectando Arritmias Cardíacas

Utilizando-se do modelo WiSARD convencional, podemos treinar um classificador com os dados do *Dataset* anteriormente descrito, capaz de distinguir dentre os 16 possíveis diagnósticos de arritmia cardíaca. Primeiramente, como existem dados contínuos faltosos, estes foram preenchidos com o valor médio do atributo. Além disso, como trata-se de um mecanismo capaz apenas de utilizar informações binárias para reconhecimento de padrões, será necessário codificar os dados contínuos e categóricos de maneira adequada, assunto sobre o qual passamos a falar.

Os atributos contínuos foram codificados através da Codificação Termômetro, a qual expressa a magnitude do número através da quantidade de bits 1 à direita. São divididos  $n$  intervalos equidistantes entre os valores mínimos e máximos do atributo, de forma que chamamos  $n$  tamanho do termômetro. Assim, verifica-se qual o  $i$ -ésimo intervalo ao qual um certo valor pertence, sendo este representado pela sequência binária de  $n$  dígitos, na qual os  $i$  algarismos à direita são 1 e os demais 0. A Tabela 1 apresenta um exemplo de Codificação Termômetro de tamanho 5, sobre o intervalo de 0 a 100.

Os atributos categóricos foram representados através de *One-Hot-Encoding*, o qual consiste numa sequência binária com apenas um bit 1, de forma que a categoria é distinguida pela posição de ocorrência deste bit positivo. A quantidade de bits utilizada na representação é dada pela quantidade de valores distintos que o campo pode assumir. A Tabela 2 ilustra o funcionamento da codificação para um atributo categórico cujos possíveis valores são  $A$ ,  $B$ , e  $C$ .

Durante a realização dos experimentos, constatou-se que frequentemente ocorriam empates dentre os discriminadores, fazendo com que o classificador cometesse

Intervalo	Codificação termômetro correspondente
$0 \leq x \leq 20$	00001
$20 < x \leq 40$	00011
$40 < x \leq 60$	00111
$60 < x \leq 80$	01111
$80 < x \leq 100$	11111

**Tabela 1. Exemplo de codificação termômetro de tamanho 5, sobre o intervalo de 0 a 100**

Categoria	<i>One-Hot-Enconding</i> correspondente
<i>A</i>	001
<i>B</i>	010
<i>C</i>	100

**Tabela 2. Exemplo de *One-Hot-Enconding* para as categorias *A*, *B*, e *C***

muitos equívocos. Para contornar a situação, utilizou-se da técnica de desempate Bleaching [Grieco et al. 2010], tendo-se estipulado um limite máximo de bleaching arbitrário de valor 15. Tal limite foi estipulado pois em certos casos o limiar de bleaching subia indefinidamente sem que fosse possível desempatar. O valor 15, escolhido de maneira arbitrária, pode ser justificado pelo fato de que frequentemente um limiar de valor abaixo de 5 era suficiente para desempatar, excetuando-se principalmente nos casos no qual o limiar de bleaching subia indefinidamente.

O *Dataset* foi particionado em duas partições, selecionando-se as amostras por sexo, de forma que foi treinado um classificador exclusivo para cada partição. Tal divisão proporcionou uma melhora significativa na acurácia do modelo, se comparado ao treinamento com o *Dataset* por inteiro num único classificador.

Tal organização do modelo proporciona alguns parâmetros que podem ser ajustados, os quais são: o tamanho do termômetro e o tamanho de endereçamento (o qual define a quantidade de RAMs). Além disso, também podemos avaliar qual combinação do uso de parâmetros apresenta melhor acurácia: apenas categóricos, apenas contínuos ou ambos. Para um ajuste destes parâmetros, utilizamos o método Grid Search, o qual consiste simplesmente na avaliação de todas as combinações possíveis dada uma lista de valores admissíveis para cada parâmetro.

Os tamanhos de termômetro avaliados foram de 4 a 15, de forma que a quantidade de colunas da matriz codificada pode variar. Com isso, a lista de valores admissíveis de tamanho de endereçamento foi construída dinamicamente de acordo com a quantidade de colunas existentes, sendo selecionados os 5 primeiros divisores não triviais da quantidade de colunas, de forma a se utilizar totalmente o endereçamento de cada uma das RAMs criadas. Por exemplo, para uma matriz codificada que possui 3090 colunas, avaliamos os tamanhos de endereçamento 2, 3, 5, 6 e 10, produzindo respectivamente 1545, 1030, 618, 515 e 309 RAMs.

#### 4. Resultados

Os experimentos foram desenvolvidos na linguagem Python, e executados numa máquina com processador Intel(R) Core(TM) i7-4510U CPU @ 2.00GHz e 8GB RAM, no Sistema

Operacional Microsoft(R) Windows 10.

A avaliação da acurácia do classificador deu-se através do *10-fold-cross-validation*, na qual o *Dataset* é dividido aleatoriamente em 10 fatias de mesmo tamanho, avaliando-se o desempenho do classificador em 10 rodadas. Na  $i$ -ésima rodada a  $i$ -ésima fatia é utilizada como conjunto de teste, e as demais como conjunto de treinamento. O processo de treinamento e teste é repetido 10 vezes, tomando cada uma das fatias como conjunto de teste, e aferindo-se a acurácia média dentre todas as rodadas.

Avaliando-se todas as configurações descritas anteriormente através da técnica *10-fold-cross-validation*, a melhor configuração avaliada atingiu a acurácia de 62,24%, sendo esta descrita abaixo:

- Uso dos atributos: apenas contínuos
- Tamanho do termômetro: 14 bits
- Tamanho de endereçamento: 4 bits

## 5. Conclusão

Podemos concluir que o modelo WiSARD foi capaz de atingir resultados de boa qualidade no problema de classificação de arritmias cardíaca, apresentando uma acurácia superior em 0,24% ao resultado publicado para o *Dataset* em questão. Também pode-se perceber que a codificação da entrada é uma etapa crucial para o um bom aproveitamento do modelo. Adicionalmente, o particionamento do *Dataset* de acordo com o sexo foi essencial na obtenção de resultados equiparáveis ao publicado.

## Referências

- Aleksander, I., Thomas, W., and Bowden, P. (1984). Wisard: a radical step forward in image recognition. *Sensor review*, 4(3):120–124.
- Grieco, B. P. A., Lima, P. M. V., De Gregorio, M., and França, F. M. G. (2010). Producing pattern examples from "mental" images. *Neurocomput.*, 73(7-9):1057–1064.
- Güvenir, H., Acar, B., Demiröz, G., et al. (1997). A supervised machine learning algorithm for arrhythmia analysis. In *Computers in Cardiology 1997*, pages 433–436. IEEE.
- Karhe, R. (2014). Ecg signal analysis techniques- a survey approach. *International Journal of Advanced Electronics and Communication Systems*, 0(0).
- Life in The Fastlane. The p wave, disponível em <http://lifeinthefastlane.com/ecg-library/basics/p-wave/>.
- Martin-Garcia, J. F., Mora-Jiménez, I., Garcia-Alberola, A., and Rojo-Alvarez, J. L. (2014). Cardiac arrhythmia discrimination using evolutionary computation. In *Computing in Cardiology Conference (CinC), 2014*, pages 121–124. IEEE.
- Salem, A. B. M., Revett, K., and El-Dahshan, E.-S. A. (2009). Machine learning in electrocardiogram diagnosis. In *Computer Science and Information Technology, 2009. IMCSIT'09. International Multiconference on*, pages 429–433. IEEE.
- UCI Machine Learning Repository (1998). Arrhythmia dataset, disponível em <https://archive.ics.uci.edu/ml/datasets/Arrhythmia>.